

YAHIA KHROUFI

Data Engineer (Stage PFE) | Big Data & Cloud | Pipelines Batch & Temps Réel

Fès, Maroc | +212 642-047321 | yahiakhroufi@gmail.com
linkedin.com/in/yahia-khroufi | github.com/yahia-khroufi

PROFIL

Étudiant en M2 Data Engineering (double diplôme Sorbonne Paris Nord / USMBA), spécialisé dans la conception de pipelines batch et streaming sur Azure. Recherche un stage PFE Data Engineer de 4 à 6 mois. Expérience concrète en architecture Medallion, ingestion temps réel (Kafka/Spark) et cloud Azure via plusieurs projets end-to-end.

FORMATION

M2 (en cours) - Parcours EID² : Exploration Informatique des Données et Décisionnel	2026-2027
Université Sorbonne Paris Nord & FSDM-USMBA, Fès Double diplôme	
M1- Master WISD : Web Intelligence et Science des Données	2025-2026
FSDM-USMBA, Fès	
Licence en Sciences Mathématiques et Informatique (SMI)	2022-2025
FSDM-USMBA, Fès	
Baccalauréat en Sciences Physiques	2021-2022
Lycée Ibn Al Haytam	

COMPÉTENCES TECHNIQUES

Langages : Python, SQL, Bash

Data Engineering : ETL/ELT, Apache Spark, PySpark, Spark Structured Streaming, Apache Kafka, Apache Airflow, Apache NiFi

Architecture & Pipelines : Data Lake, Architecture Medallion (Bronze / Silver / Gold), pipelines batch et streaming, ingestion, transformation, Data Quality

Cloud / Azure : Microsoft Azure, Azure Data Factory, ADLS Gen2, Azure Databricks, Delta Lake, Azure SQL, Synapse Analytics

Bases de données : PostgreSQL, Apache Cassandra, SQL Server

DevOps / Outils : Docker, Docker Compose, Git, GitHub, Linux, Power BI, Streamlit, Pandas

EXPÉRIENCE PROFESSIONNELLE

Stage Data Engineering — Cabinet ABIsoft

Fès, Maroc | Juin 2026

- Préparation et intégration de données juridiques pour une application de recherche documentaire.
- Développement de scripts Python et Pandas pour extraire, nettoyer, normaliser et charger les données dans PostgreSQL.
- Création de requêtes SQL et de contrôles de qualité pour vérifier la cohérence des données intégrées.

Technologies : Python, Pandas, SQL, PostgreSQL, Git

PROJETS DATA ENGINEERING

Azure Weather Data Platform - Batch Data Engineering Pipeline

[GitHub](#)

Stack : Azure Data Factory, ADLS Gen2, Azure Databricks, PySpark, Delta Lake, Azure SQL, Synapse Analytics, Power BI

- Conception d'un pipeline batch pour ingérer les données de l'API OpenWeather via Azure Data Factory et les stocker dans ADLS Gen2.
- Transformation des données avec PySpark sur Azure Databricks selon une architecture Médaille Bronze/Silver/Gold.
- Mise à disposition des données dans Azure SQL et Synapse Analytics pour leur exploitation avec Power BI.

IoTFlow - Real-Time Data Engineering Platform

[GitHub](#) | [Démonstration](#)

Stack : Apache NiFi, Apache Kafka, Spark Structured Streaming, Apache Cassandra, Apache Airflow, Streamlit, Docker

- Conception d'une plateforme temps réel pour l'ingestion et le traitement de métriques IoT et système.
- Mise en place d'un pipeline NiFi → Kafka → Spark Structured Streaming pour collecter, valider et transformer les événements.
- Stockage dans Cassandra, orchestration avec Airflow et visualisation des données avec Streamlit.

CERTIFICATIONS

IBM Data Engineering Professional Certificate — IBM | Credly

Juil. 2026

LANGUES

Arabe : langue maternelle | **Français** : niveau intermédiaire | **Anglais** : niveau intermédiaire